尚硅谷大数据项目之 Spark 实时（数据采集）

（作者：尚硅谷研究院）

版本：V2.0

第 1 章 简介

1.1 离线计算

离线计算一般指通过批处理的方式计算已知的所有输入数据，输入数据不会产生变化，一般计算量级较大，计算时间较长。

例如今天凌晨一点，把昨天累积的日志，计算出所需结果。最经典的就是 Hadoop 的 MapReduce 方式；

一般需要根据前一日的数据生成报表，虽然统计指标、报表繁多，但是对时效性不敏感。

1.1.1 离线计算的特点

（1）数据在计算前已经全部就位，不会发生变化

（2）数据量大且保存时间长

（3）在大量数据上进行复杂的批量运算

（4）方便的查看批量计算的结果

1.2 实时计算

实时计算一般是指通过流处理方式计算当日的数据都算是实时计算。

也会有一些准实时计算，利用离线框架通过批处理完成（小时、10 分钟级）的计算，一般为过渡产品，不能算是实时计算。

1.2.1 实时计算特点

1）局部计算

每次计算以输入的每条数据，或者微批次、小窗口的数据范围进行计算，没法像离线数据一样能够基于当日全部数据进行统计排序分组。

2）开发成本较高

相比离线的批处理 SQL，实时计算需要通过代码，往往需要对接多种数据容器完成，相对开发较为复杂。

3）资源成本较高

实时计算虽然单位时间内数据量不如批处理，但是需要 24 小时不停进行运行，一旦计算资源投入就无法释放，所以每个任务都要合理分配资源。

4）时效性

实时计算往往对时效性有一定的要求，所以要尽量优化整个计算链，减少计算过程中的中间环节。

5）可视化性

因为数据是不断变化的，所以相对于严谨整齐的离线报表，实时数据更寄希望通过图形化的手段能够及时的观察到数据趋势。

1.3 数仓架构设计

1.3.1 离线架构

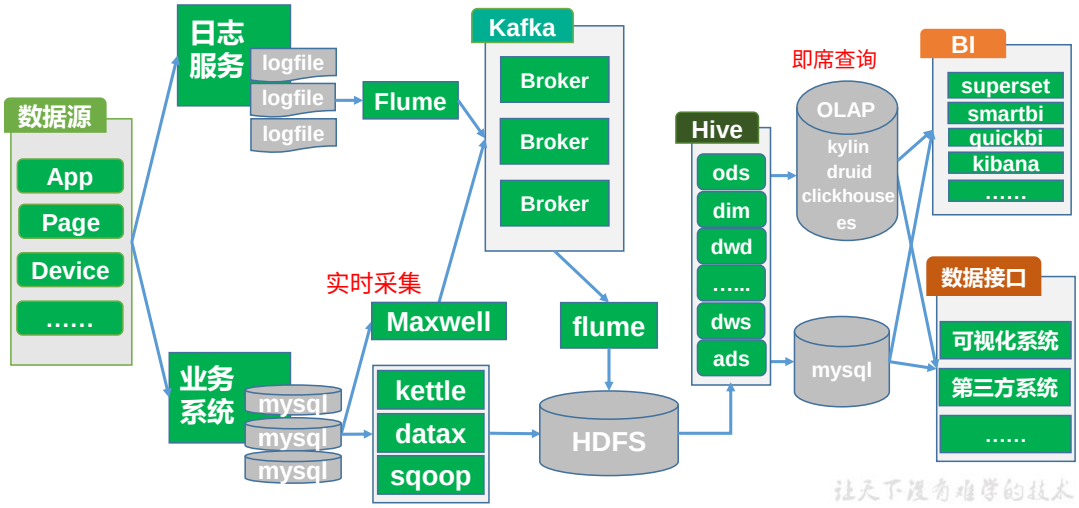

1.3.2 实时架构

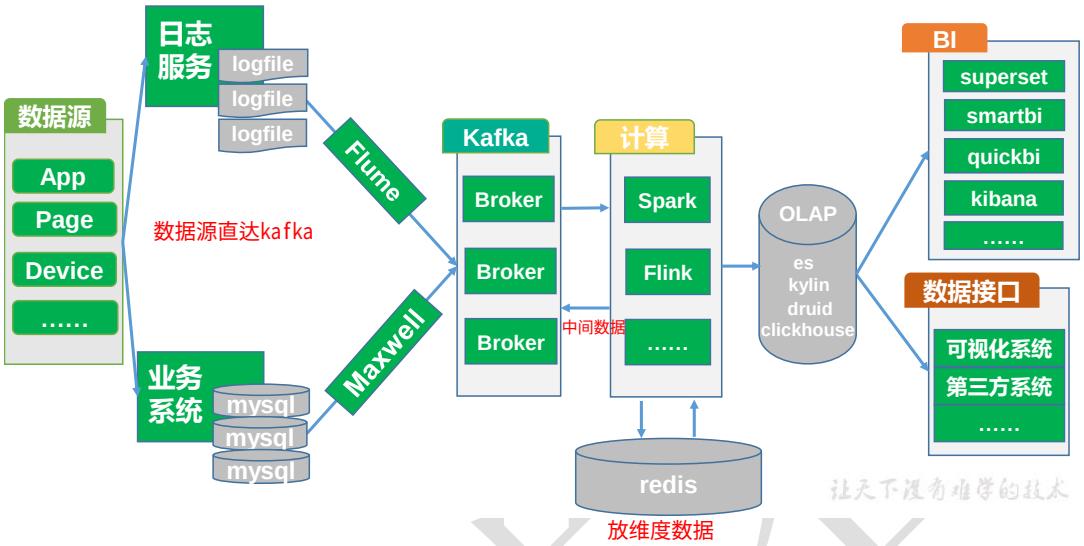

1.4 项目需求

1.4.1 BI 分析

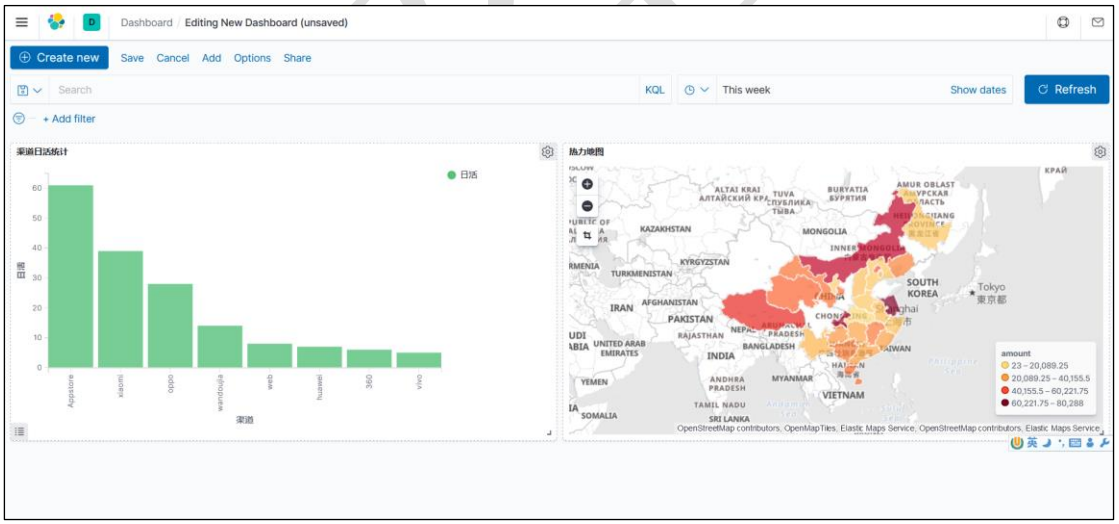

1.4.2 数据接口应用

1）日活实时统计

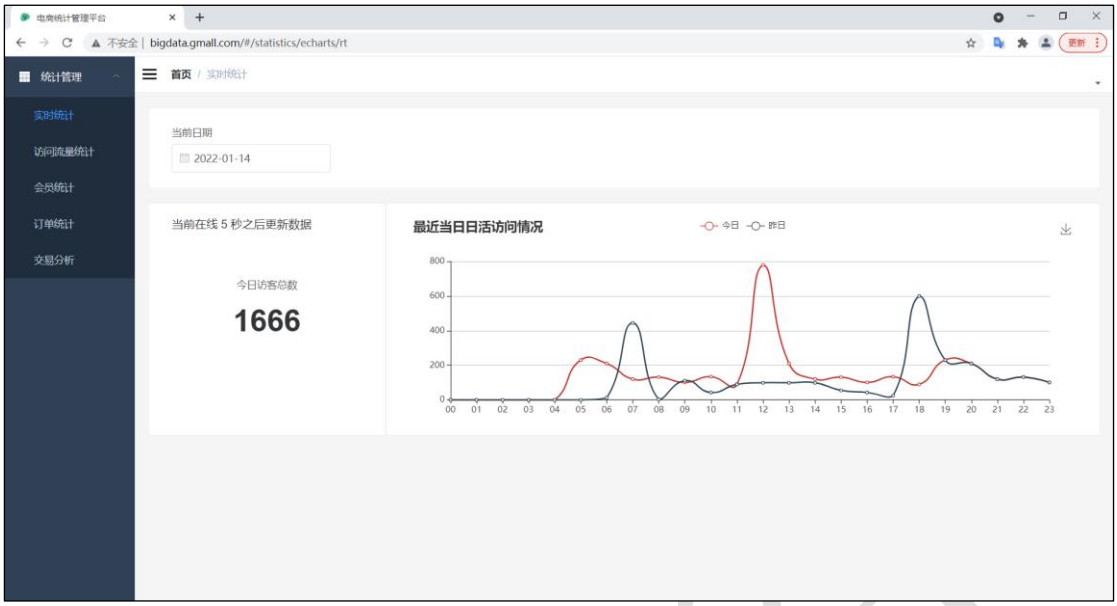

2）订单交易分析

第 2 章 日志数据采集和分流

2.1 整体架构

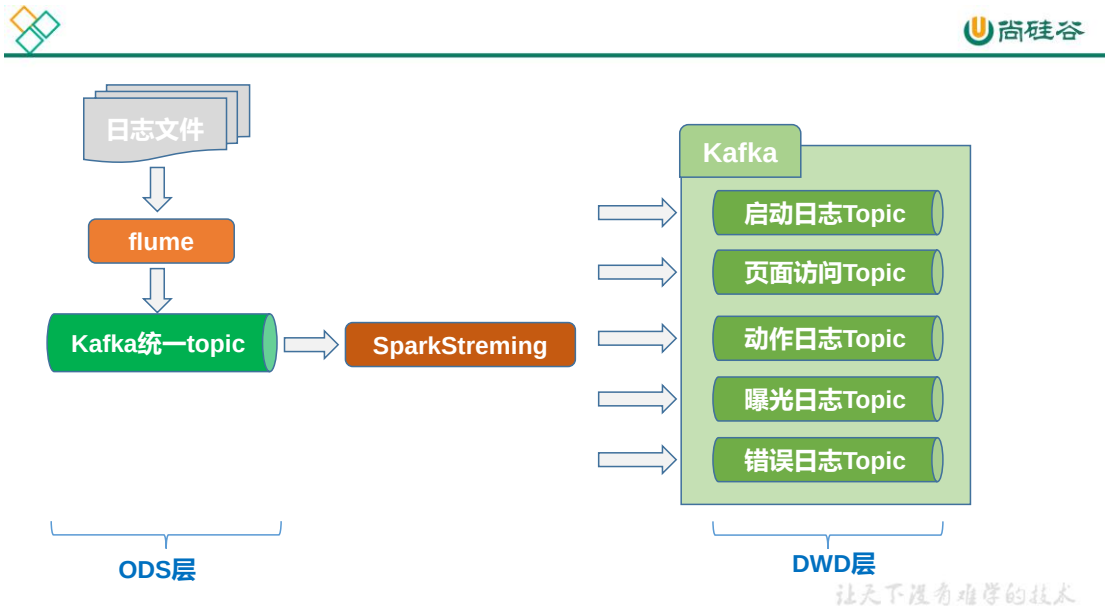

2.2 采集日志数据

1）上传模拟日志数据生成器到/opt/module/applog 目录

```
[atguigu@hadoop102 applog]$ ll
总用量 15288
-rw-r--r--. 1 atguigu atguigu      979 9 月  18 09:24 application.yml
-rw-r--r--.  1  atguigu  atguigu  15640308  2  月        1  2021
gmall2020-mock-log-2021-01-22.jar
-rw-r--r--. 1 atguigu atguigu     1039 2 月   1 2021  logback.xml
-rw-r--r--. 1 atguigu atguigu      565 2 月   1 2021  path.json
```

2）根据实际需要修改 application.yml 的如下配置

```
#业务日期
mock.date: "2020-06-20"

#模拟数据发送模式
mock.type:"kafka"

#kafka 模式下，发送的地址
mock:
  kafka-server: "hadoop102:9092,hadoop103:9092,hadoop104:9092"
  kafka-topic: "ODS_BASE_LOG"
```

3）生成数据测试

```
[atguigu@hadoop102          applog]$          java          -jar
gmall2020-mock-log-2021-01-22.jar
```

4）消费数据测试

```
[atguigu@hadoop102 applog]$ kafka-console-consumer.sh
--bootstrap-server=hadoop102:9092,hadoop103:9092,hadoop104:9092 --
topic ODS_BASE_LOG
```

2.3 辅助脚本

1）模拟生成数据脚本 log.sh

```
#!/bin/bash
#根据传递的日期参数修改配置文件的日期
if [ $# -ge 1 ]
then
    sed -i "/mock.date/c mock.date: $1"
/opt/module/applog/application.yml
fi
cd /opt/module/applog;java -jar
gmall2020-mock-log-2021-11-29.jar >/dev/null 2>&1 &
```

2）Kafka 脚本

```
#!/bin/bash
if [ $# -lt 1 ]
then
  echo "Usage: kf.sh {start|stop|kc [topic]|kp [topic] |list |delete
[topic] |describe [topic]}"
  exit
fi
case $1 in
start)
    for i in hadoop102 hadoop103 hadoop104
    do
      echo "====================> START $i KF <===================="
      ssh $i kafka-server-start.sh -daemon
/opt/module/kafka_2.11-2.4.1/config/server.properties
    done
;;

stop)
    for i in hadoop102 hadoop103 hadoop104
    do
      echo "====================> STOP $i KF <===================="
      ssh $i kafka-server-stop.sh
    done
;;
kc)
    if [ $2 ]
    then
       kafka-console-consumer.sh --bootstrap-server
hadoop102:9092,hadoop103:9092,hadoop104:9092 --topic $2
    else
        echo "Usage: kf.sh {start|stop|kc [topic]|kp [topic] |list
|delete [topic] |describe [topic]}"
    fi
;;
kp)
```

```
    if [ $2 ]
    then
      kafka-console-producer.sh                          --broker-list
hadoop102:9092,hadoop103:9092,hadoop104:9092 --topic $2
    else
      echo "Usage: kf.sh {start|stop|kc [topic]|kp [topic] |list
|delete [topic] |describe [topic]}"
    fi
;;

list)
    kafka-topics.sh             --list             --bootstrap-server
hadoop102:9092,hadoop103:9092,hadoop104:9092
;;
describe)
    if [ $2 ]
    then
     kafka-topics.sh          --describe          --bootstrap-server
hadoop102:9092,hadoop103:9092,hadoop104:9092 --topic $2
    else
     echo "Usage: kf.sh {start|stop|kc [topic]|kp [topic] |list
|delete [topic] |describe [topic]}"
    fi
;;

delete)
    if [ $2 ]
    then
     kafka-topics.sh           --delete           --bootstrap-server
hadoop102:9092,hadoop103:9092,hadoop104:9092 --topic $2
    else
     echo "Usage: kf.sh {start|stop|kc [topic]|kp [topic] |list
|delete [topic] |describe [topic]}"
    fi
;;
*)
   echo "Usage: kf.sh {start|stop|kc [topic]|kp [topic] |list |delete
[topic] |describe [topic]}"
   exit
;;
esac
```

2.4 准备开发环境

2.4.1 创建工程

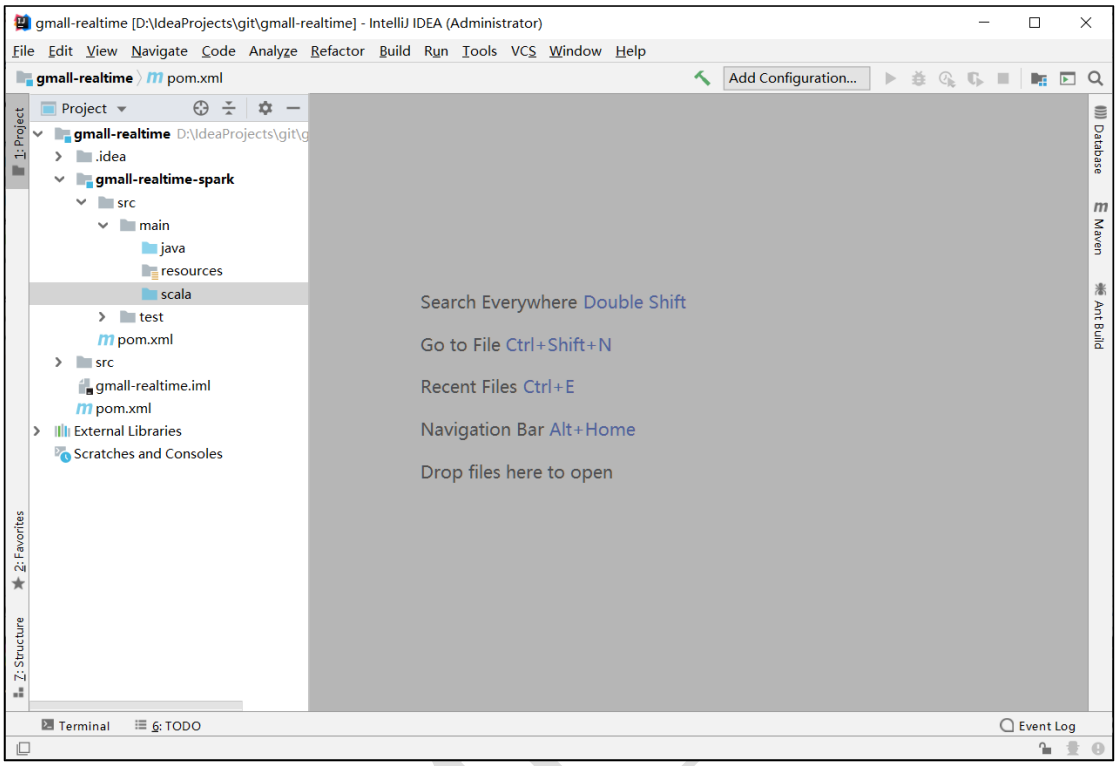

2.4.2 添加依赖

```
    <properties>
        <spark.version>3.0.0</spark.version>
        <scala.version>2.12.11</scala.version>
        <kafka.version>2.4.1</kafka.version>

<project.build.sourceEncoding>UTF-8</project.build.sourceEncoding
>

<project.reporting.outputEncoding>UTF-8</project.reporting.output
Encoding>
        <java.version>1.8</java.version>
    </properties>

    <dependencies>
        <dependency>
            <groupId>com.alibaba</groupId>
            <artifactId>fastjson</artifactId>
            <version>1.2.62</version>
        </dependency>

        <dependency>
            <groupId>org.apache.spark</groupId>
            <artifactId>spark-core_2.12</artifactId>
```

```
            <version>${spark.version}</version>
        </dependency>
        <dependency>
            <groupId>org.apache.spark</groupId>
            <artifactId>spark-streaming_2.12</artifactId>
            <version>${spark.version}</version>
        </dependency>
        <dependency>
            <groupId>org.apache.kafka</groupId>
            <artifactId>kafka-clients</artifactId>
            <version>${kafka.version}</version>

        </dependency>
        <dependency>
            <groupId>org.apache.spark</groupId>

<artifactId>spark-streaming-kafka-0-10_2.12</artifactId>
            <version>${spark.version}</version>
        </dependency>

        <dependency>
            <groupId>org.apache.spark</groupId>
            <artifactId>spark-sql_2.12</artifactId>
            <version>${spark.version}</version>
        </dependency>

        <dependency>
            <groupId>com.fasterxml.jackson.core</groupId>
            <artifactId>jackson-core</artifactId>
            <version>2.11.0</version>
        </dependency>

        <dependency>
            <groupId>org.apache.logging.log4j</groupId>
            <artifactId>log4j-to-slf4j</artifactId>
            <version>2.11.0</version>
        </dependency>

        <dependency>
            <groupId>mysql</groupId>
            <artifactId>mysql-connector-java</artifactId>
            <version>5.1.47</version>
        </dependency>

        <dependency>
            <groupId>redis.clients</groupId>
            <artifactId>jedis</artifactId>
            <version>3.3.0</version>
        </dependency>

        <dependency>
            <groupId>org.elasticsearch</groupId>
            <artifactId>elasticsearch</artifactId>
            <version>7.8.0</version>
        </dependency>
```

```
        <dependency>
            <groupId>org.elasticsearch.client</groupId>

<artifactId>elasticsearch-rest-high-level-client</artifactId>
            <version>7.8.0</version>
        </dependency>

        <dependency>
            <groupId>org.apache.httpcomponents</groupId>
            <artifactId>httpclient</artifactId>
            <version>4.5.10</version>
        </dependency>

    </dependencies>

    <build>
        <plugins>
            <!-- 该插件用于将 Scala 代码编译成 class 文件 -->
            <plugin>
                <groupId>net.alchim31.maven</groupId>
                <artifactId>scala-maven-plugin</artifactId>
                <version>3.4.6</version>
                <executions>
                    <execution>
                        <!-- 声明绑定到 maven 的 compile 阶段 -->
                        <goals>
                            <goal>compile</goal>
                            <goal>testCompile</goal>
                        </goals>
                    </execution>
                </executions>
            </plugin>

            <plugin>
                <groupId>org.apache.maven.plugins</groupId>
                <artifactId>maven-assembly-plugin</artifactId>
                <version>3.0.0</version>
                <configuration>
                    <descriptorRefs>

<descriptorRef>jar-with-dependencies</descriptorRef>
                    </descriptorRefs>
                </configuration>
                <executions>
                    <execution>
                        <id>make-assembly</id>
                        <phase>package</phase>
                        <goals>
                            <goal>single</goal>
                        </goals>
                    </execution>
                </executions>
            </plugin>
        </plugins>
    </build>
```

2.4.3 添加配置文件

1）添加 config.properties 文件

```
# Kafka 配置
kafka.broker.list=hadoop102:9092,hadoop103:9092,hadoop104:9092
```

2）添加 log4j.properties

```
log4j.appender.atguigu.MyConsole=org.apache.log4j.ConsoleAppender
log4j.appender.atguigu.MyConsole.target=System.out
log4j.appender.atguigu.MyConsole.layout=org.apache.log4j.PatternL
ayout
log4j.appender.atguigu.MyConsole.layout.ConversionPattern=%d{yyyy
-MM-dd HH:mm:ss} %10p (%c:%M) - %m%n
log4j.rootLogger =error,atguigu.MyConsole
```

2.4.4 添加工具类

1）properties 工具类

```
package com.atguigu.gmall.realtime.util
import java.util.ResourceBundle

/**
  * 配置解析类
  */
object PropertiesUtils {

  private val bundle: ResourceBundle =
ResourceBundle.getBundle("config")

  def apply(key : String ):String ={
    bundle.getString(key)
  }

  def main(args: Array[String]): Unit = {
    println(PropertiesUtils("kafka.broker.list"))
  }
}
```

2）Kafka 工具类

```
package com.atguigu.gmall.realtime.util

import java.util.Properties

import org.apache.kafka.clients.consumer.{ConsumerConfig,
ConsumerRecord}
import org.apache.kafka.clients.producer
import org.apache.kafka.clients.producer.{KafkaProducer,
ProducerConfig, ProducerRecord}
import org.apache.kafka.common.TopicPartition
import org.apache.spark.streaming.StreamingContext
import org.apache.spark.streaming.dstream.InputDStream
import org.apache.spark.streaming.kafka010.{ConsumerStrategies,
KafkaUtils, LocationStrategies}
```

```
import scala.collection.mutable

/**
  * Kafka 工具类，用于生产和消费
  */
object MyKafkaUtils {

  //kafka 消费配置
  private val consumerConfig: mutable.Map[String, String] =
mutable.Map(
    ConsumerConfig.BOOTSTRAP_SERVERS_CONFIG ->
PropertiesUtils("kafka.bootstrap.servers"),
    ConsumerConfig.KEY_DESERIALIZER_CLASS_CONFIG ->
"org.apache.kafka.common.serialization.StringDeserializer",
    ConsumerConfig.VALUE_DESERIALIZER_CLASS_CONFIG ->
"org.apache.kafka.common.serialization.StringDeserializer",
    ConsumerConfig.GROUP_ID_CONFIG -> "gmall",
    ConsumerConfig.AUTO_OFFSET_RESET_CONFIG -> "latest",
    ConsumerConfig.ENABLE_AUTO_COMMIT_CONFIG -> "true"
  )


  /**
    * 默认 offsets 位置消费
    */
  def getKafkaDStream(topic:String,ssc:
StreamingContext,groupId:String) :
InputDStream[ConsumerRecord[String, String]] ={
    consumerConfig(ConsumerConfig.GROUP_ID_CONFIG) = groupId
    val dStream: InputDStream[ConsumerRecord[String, String]] =
KafkaUtils.createDirectStream[String, String](
      ssc,
      LocationStrategies.PreferConsistent,
      ConsumerStrategies.Subscribe[String, String](Array(topic),
consumerConfig)
    )
    dStream
  }

  /**
    * 指定 offsets 位置消费
    */
  def getKafkaDStream(topic:String,ssc: StreamingContext,offsets:
Map[TopicPartition,Long],groupId : String ) :
InputDStream[ConsumerRecord[String, String]] ={
    consumerConfig(ConsumerConfig.GROUP_ID_CONFIG) = groupId
    val dStream: InputDStream[ConsumerRecord[String, String]] =
KafkaUtils.createDirectStream[String, String](
      ssc,
      LocationStrategies.PreferConsistent,
      ConsumerStrategies.Subscribe[String, String](Array(topic),
consumerConfig,offsets)
    )
    dStream
  }
```

```
  /**
    * 创建 Kafka 生产者对象
    */
  def createKafkaProducer():KafkaProducer[String,String] = {
    //Kafka 生产配置
    val props = new Properties()

props.put(ProducerConfig.BOOTSTRAP_SERVERS_CONFIG,PropertiesUtils
("kafka.bootstrap.servers"))

props.put(ProducerConfig.KEY_SERIALIZER_CLASS_CONFIG,"org.apache.
kafka.common.serialization.StringSerializer")

props.put(ProducerConfig.VALUE_SERIALIZER_CLASS_CONFIG,"org.apach
e.kafka.common.serialization.StringSerializer")
    props.put(ProducerConfig.ENABLE_IDEMPOTENCE_CONFIG,"true")

    val      producer:KafkaProducer[String,String]      =      new
KafkaProducer[String,String](props)
    producer
  }

  private var producer : KafkaProducer[ String , String ] =
createKafkaProducer()

  /**
    * 生产
    */
  def send(topic:String, msg :String):Unit={
     producer.send(new ProducerRecord[String,String](topic,msg))
  }

  /**
    * 生产 指定 key
    */
  def send(topic:String, key: String , msg :String):Unit = {
    producer.send(new      ProducerRecord[String,String](topic,key,
msg))
  }

/**
    * 刷写缓冲区
    */

def flush(): Unit = {
  if(producer != null ) producer.flush()
}

  /**
    * 关闭生产者对象
    */
  def close():Unit = {
    if(producer != null ) producer.close()
  }
```

```
}
```

2.5 日志数据消费分流

2.5.1 相关实体 bean

1）页面日志 Bean

```
case class PageLog(
                   mid :String,
                   user_id:String,
                   province_id:String,
                   channel:String,
                   is_new:String,
                   model:String,
                   operate_system:String,
                   version_code:String,
                   page_id:String ,
                   last_page_id:String,
                   page_item:String,
                   page_item_type:String,
                   during_time:Long,
                   ts:Long
                 ) {

}
```

2）启动日志 Bean

```
case class StartLog(
mid :String,
             user_id:String,
             province_id:String,
             channel:String,
             is_new:String,
             model:String,
             operate_system:String,
             version_code:String,
             entry:String,
             open_ad_id:String,
             loading_time_ms:Long,
             open_ad_ms:Long,
             open_ad_skip_ms:Long,
             ts:Long) {

}
```

3）页面动作日志 Bean

```
case class PageActionLog(
                   mid :String,
                   user_id:String,
                   province_id:String,
                   channel:String,
                   is_new:String,
                   model:String,
                   operate_system:String,
```

```
                    version_code:String,
                    page_id:String ,
                    last_page_id:String,
                    page_item:String,
                    page_item_type:String,
                    during_time:Long,
                    action_id:String,
                    action_item:String,
                    action_item_type:String,
                    ts:Long
                ) {

}
```

4）页面曝光日志 Bean

```
case class PageDisplayLog (
                        mid :String,
                        user_id:String,
                        province_id:String,
                        channel:String,
                        is_new:String,
                        model:String,
                        operate_system:String,
                        version_code:String,
                        page_id:String ,
                        last_page_id:String,
                        page_item:String,
                        page_item_type:String,
                        during_time:Long,
                        display_type:String,
                        display_item: String,
                        display_item_type:String,
                        display_order:String ,
                        display_pos_id:String,
                        ts:Long
                       )
```

2.5.2 消费分流

1）代码

```
package com.atguigu.gmall.realtime.app

import com.alibaba.fastjson.serializer.SerializeConfig
import com.alibaba.fastjson.{JSON, JSONArray, JSONObject}
import              com.atguigu.gmall.realtime.bean.{PageActionLog,
PageDisplayLog, PageLog, StartLog}
import com.atguigu.gmall.realtime.util.MyKafkaUtils
import org.apache.kafka.clients.consumer.ConsumerRecord
import org.apache.spark.SparkConf
import org.apache.spark.rdd.RDD
import org.apache.spark.streaming.dstream.{DStream, InputDStream}
import org.apache.spark.streaming.{Seconds, StreamingContext}

/**
  * 消费分流
```

```
 * 1. 接收 Kafka 数据流
 *
 * 2. 转换数据结构:
 *      通用的数据结构: Map 或者 JsonObject
 *      专用的数据结构: bean
 *
 * 3. 分流 : 将数据拆分到不同的主题中
 *      启动主题: DWD_START_LOG
 *      页面访问主题: DWD_PAGE_LOG
 *      页面动作主题:DWD_PAGE_ACTION
 *      页面曝光主题:DWD_PAGE_DISPLAY
 *      错误主题:DWD_ERROR_INFO
 */
object BaseLogApp {

  def main(args: Array[String]): Unit = {

    //创建配置对象
    val sparkConf: SparkConf = new
SparkConf().setAppName("base_log_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkConf,Seconds(5))

    //原始主题
    val ods_base_topic : String = "ODS_BASE_LOG"
    //启动主题
    val dwd_start_log : String = "DWD_START_LOG"
    //页面访问主题
    val dwd_page_log : String = "DWD_PAGE_LOG"
    //页面动作主题
    val dwd_page_action : String = "DWD_PAGE_ACTION"
    //页面曝光主题
    val dwd_page_display : String  = "DWD_PAGE_DISPLAY"
    //错误主题
    val dwd_error_info : String  ="DWD_ERROR_INFO"

    //消费组
    val group_id : String = "ods_base_log_group"


    //1. 接收 Kafka 数据流
    val kafkaDStream: InputDStream[ConsumerRecord[String, String]] =
       MyKafkaUtils.getKafkaDStream(ods_base_topic,ssc,group_id)

    //kafkaDStream.map(_.value()).print(3)

    //2. 转换数据结构
    val jsonDStream: DStream[JSONObject] = kafkaDStream.map(
      record => {

        val value: String = record.value()
        println(value)
        val jsonObject: JSONObject = JSON.parseObject(value)
```

```
        jsonObject
      }
    )

    //3.切分数据分流
    jsonDStream.foreachRDD(
      rdd => {
        rdd.foreach(
          jsonObj => {
            //TODO 错误日志
            //分流错误日志 判断是否是错误日志，如果是错误日志，直接发送
            val errorObj: JSONObject = jsonObj.getJSONObject("err")
            if(errorObj !=null){
              MyKafkaUtils.send(dwd_error_info,jsonObj.toJSONString)
            }else{
              //提取公共信息
              val commonObj: JSONObject =
jsonObj.getJSONObject("common")
              val mid: String = commonObj.getString("mid")
              val uid: String = commonObj.getString("uid")
              val ar: String = commonObj.getString("ar")
              val ch: String = commonObj.getString("ch")
              val os: String = commonObj.getString("os")
              val md: String = commonObj.getString("md")
              val vc: String = commonObj.getString("vc")
              val isNew: String = commonObj.getString("is_new")
              val ts: Long = jsonObj.getLong("ts")

              //分流页面日志
              val pageObj: JSONObject = jsonObj.getJSONObject("page")
              if(pageObj != null ){
                //提取字段
                val pageId: String = pageObj.getString("page_id")
                val pageItem: String = pageObj.getString("item")
                val pageItemType: String =
pageObj.getString("item_type")
                val lastPageId: String =
pageObj.getString("last_page_id")
                val duringTime: Long = pageObj.getLong("during_time")

                //封装 bean
                val pageLog =
                  PageLog(mid, uid, ar, ch, isNew, md, os, vc, pageId,
lastPageId, pageItem, pageItemType, duringTime, ts)
                //发送 kafka

MyKafkaUtils.send(dwd_page_log,JSON.toJSONString(pageLog,new
SerializeConfig(true)))

                //分流动作日志
                val actionArrayObj: JSONArray =
jsonObj.getJSONArray("actions")
                if(actionArrayObj != null && actionArrayObj.size() >
0 ){
                  for(i <- 0 until actionArrayObj.size() ){
```

```
                val actionObj: JSONObject =
actionArrayObj.getJSONObject(i)
                val actionId: String =
actionObj.getString("action_id")
                val actionItem: String =
actionObj.getString("item")
                val actionItemType: String =
actionObj.getString("item_type")
                //TODO actionts
                val actionTs: Long = actionObj.getLong("ts")

                //封装 Bean
                val pageActionLog =
                  PageActionLog(mid, uid, ar, ch, isNew, md, os, vc,
pageId, lastPageId, pageItem, pageItemType,
duringTime,actionId,actionItem,actionItemType,actionTs, ts)

                //发送 Kafka

MyKafkaUtils.send(dwd_page_action,JSON.toJSONString(pageActionLog
,new SerializeConfig(true)))

              }
            }

            //分流曝光日志
            val displayArrayObj: JSONArray =
jsonObj.getJSONArray("displays")
            if(displayArrayObj != null && displayArrayObj.size() >
0 ){
              for(i <- 0 until displayArrayObj.size()){
                val displayObj: JSONObject =
displayArrayObj.getJSONObject(i)
                val displayType: String =
displayObj.getString("display_type")
                val displayItem: String =
displayObj.getString("item")
                val displayItemType: String =
displayObj.getString("item_type")
                val displayOrder: String =
displayObj.getString("order")
                val displayPosId: String =
displayObj.getString("pos_id")

                //封装 Bean
                val displayLog = PageDisplayLog(mid, uid, ar, ch,
isNew, md, os, vc, pageId, lastPageId, pageItem, pageItemType,
duringTime,displayType,displayItem,displayItemType,displayOrder,d
isplayPosId,ts)
                //发送 Kafka

MyKafkaUtils.send(dwd_page_display,JSON.toJSONString(displayLog,n
ew SerializeConfig(true)))
              }
            }
```

```
            }

            //分流启动日志
            val startObj: JSONObject =
jsonObj.getJSONObject("start")
            if(startObj != null ){
              val entry: String = startObj.getString("entry")
              val loadingTimeMs: Long =
startObj.getLong("loading_time_ms")
              val openAdId: String =
startObj.getString("open_ad_id")
              val openAdMs: Long = startObj.getLong("open_ad_ms")
              val openAdSkipMs: Long =
startObj.getLong("open_ad_skip_ms")

              //封装 Bean
              val startLog =
StartLog(mid,uid,ar,ch,isNew,md,os,vc,entry,openAdId,loadingTimeM
s,openAdMs,openAdSkipMs,ts)
              //发送 Kafka

MyKafkaUtils.send(dwd_start_log,JSON.toJSONString(startLog,new
SerializeConfig(true)))
            }

          }
        }
      )
    }
  )

  ssc.start()
  ssc.awaitTermination()
 }
}
```

2.6 优化 - 精确一次消费

重复消费问题

2.6.1 相关语义

1）至少一次消费（at least once）

主要是保证数据不会丢失，但有可能存在数据重复问题。

2）最多一次消费 （at most once）

主要是保证数据不会重复，但有可能存在数据丢失问题。

3）精确一次消费（Exactly-once）

指消息一定会被处理且只会被处理一次。不多不少就一次处理。如果达不到精确一次消费，可能会达到另外两种情况。

2.6.2 消费问题

1）漏消费（丢失数据）

比如实时计算任务进行计算，到数据结果存盘之前，进程崩溃，假设在进程崩溃前 kafka 调整了偏移量，那么 kafka 就会认为数据已经被处理过，即使进程重启，kafka 也会从新的偏移量开始，所以之前没有保存的数据就被丢失掉了。

2）重复消费（重复计算）

如果数据计算结果已经存盘了，在 kafka 调整偏移量之前，进程崩溃，那么 kafka 会认为数据没有被消费，进程重启，会重新从旧的偏移量开始，那么数据就会被 2 次消费，又会被存盘，数据就被存了 2 遍，造成数据重复。

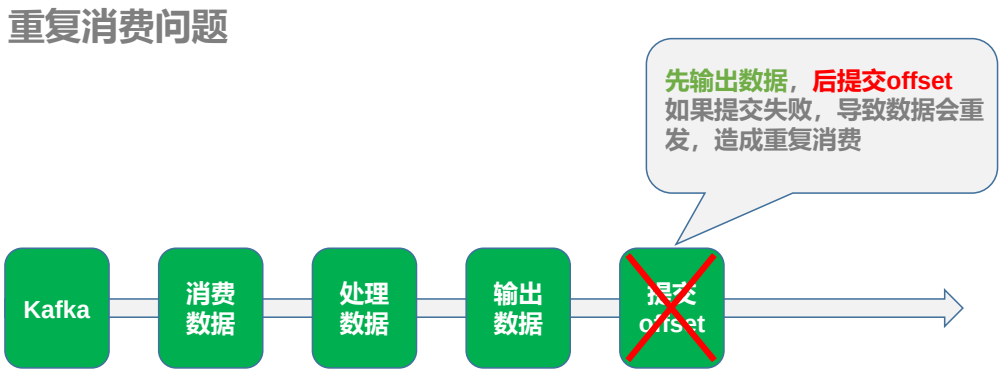

3）如果同时解决了数据丢失和数据重复的问题，那么就实现了精确一次消费的语义了。

目前 Kafka 默认每 5 秒钟做一次自动提交偏移量，这样并不能保证精准一次消费。

```
enable.auto.commit 的默认值是 true；就是默认采用自动提交的机制。
auto.commit.interval.ms 的默认值是 5000，单位是毫秒。
```

2.6.3 问题解决-策略一

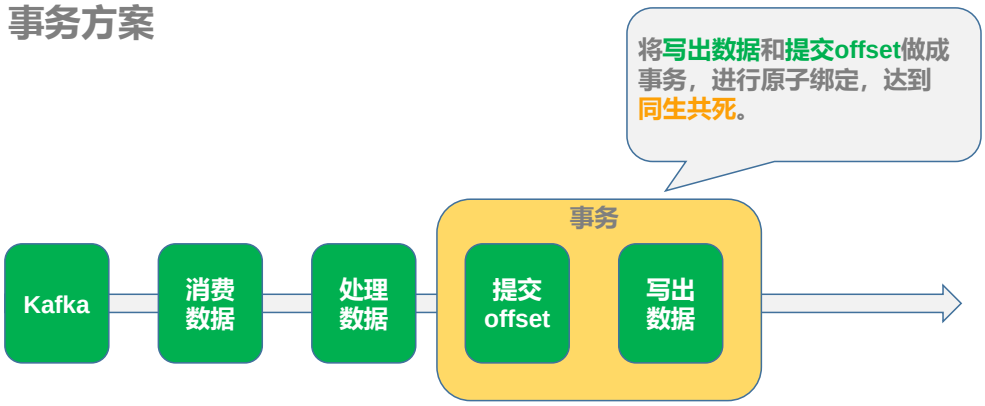

1）策略：利用关系型数据库的事务进行处理

出现丢失或者重复的问题，核心就是偏移量的提交与数据的保存，不是原子性的。如果能做成要么数据保存和偏移量都成功，要么两个失败，那么就不会出现丢失或者重复了。

这样的话可以把存数据和修改偏移量放到一个事务里。这样就做到前面的成功，如果后

面做失败了,就回滚前面那么就达成了原子性,这种情况先存数据还是先修改偏移量没影响。

2）好处

事务方式能够保证精准一次性消费

3）问题与限制

（1）数据必须都要放在一个关系型数据库中，无法使用其他功能强大的 nosql 数据库

（2）事务本身性能不好

（3）如果保存的数据量较大一个数据库节点不够，多个节点的话，还要考虑分布式事务的问题。分布式事务会带来管理的复杂性，一般企业不选择使用，有的企业会把分布式事务变成本地事务，例如把 Executor 上的数据通过 rdd.collect 算子提取到 Driver 端，由 Driver 端统一写入数据库，这样会将分布式事务变成本地事务的单线程操作，降低了写入的吞吐量。

4）使用场景

数据足够少（通常经过聚合后的数据量都比较小，明细数据一般数据量都比较大），并且支持事务的数据库。

2.6.4 问题解决-策略二

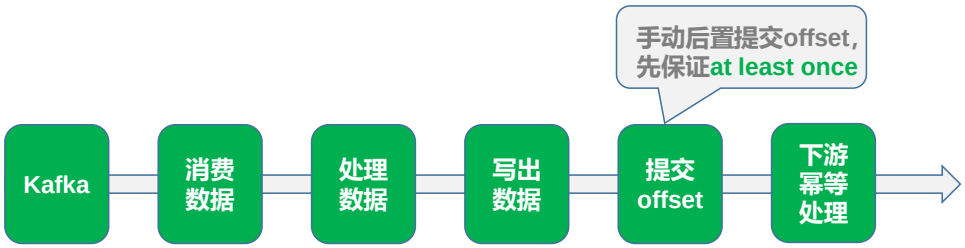

1）策略:手动提交偏移量 + 幂等性处理

我们知道如果能够同时解决数据丢失和数据重复问题，就等于做到了精确一次消费。那就各个击破。

首先解决数据丢失问题，办法就是要等数据保存成功后再提交偏移量，所以就必须手工来控制偏移量的提交时机。

但是如果数据保存了，没等偏移量提交进程挂了，数据会被重复消费。怎么办？那就要把数据的保存做成幂等性保存。即同一批数据反复保存多次，数据不会翻倍，保存一次和保存一百次的效果是一样的。如果能做到这个，就达到了幂等性保存，就不用担心数据会重复了。

2）难点

话虽如此，在实际的开发中手动提交偏移量其实不难，难的是幂等性的保存，有的时候并不一定能保证，这个需要看使用的数据库，如果数据库本身不支持幂等性操作，那只能优先保证的数据不丢失，数据重复难以避免，即只保证了至少一次消费的语义。

一般有主键的数据库都支持幂等性操作 upsert。

3）使用场景

处理数据较多，或者数据保存在不支持事务的数据库上。

2.6.5 手动提交偏移流程

1）偏移量保存在哪

kafka 0.9 版本以后 consumer 的偏移量是保存在 kafka 的__consumer_offsets 主题中。但是如果用这种方式管理偏移量，有一个限制就是在提交偏移量时，数据流的元素结构不能发生转变，即提交偏移量时数据流，必须是 InputDStream[ConsumerRecord[String, String]]这种结构。但是在实际计算中，数据难免发生转变，或聚合，或关联，一旦发生转变，就无法在利用以下语句进行偏移量的提交：

```
xxDstream.asInstanceOf[CanCommitOffsets].commitAsync(offsetRanges)
```

因为 offset 的存储于 HasOffsetRanges，只有 kafkaRDD 继承了他，所以假如我们对 KafkaRDD 进行了转化之后，其它 RDD 没有继承 HasOffsetRanges，所以就无法再获取 offset 了。

所以实际生产中通常会利用 ZooKeeper,Redis,Mysql 等工具手动对偏移量进行保存

2）流程

offset管理方案

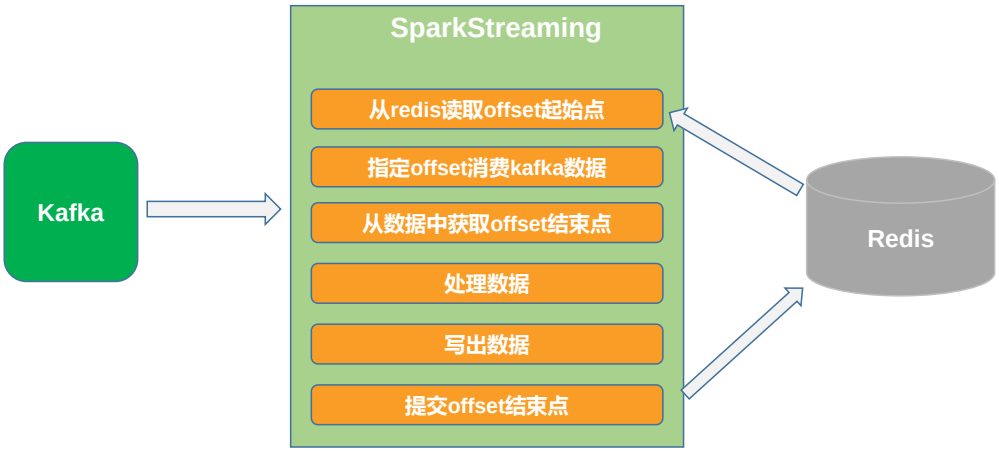

2.6.6 代码实现

1）在 config.properties 中添加 redis 的连接配置

```
# Kafka 通用配置
kafka.bootstrap.servers=hadoop102:9092,hadoop103:9092,hadoop104:9092

#Redis 配置
redis.host=hadoop102
redis.port=6379
```

2）添加 Redis 工具类

```
package com.atguigu.gmall.realtime.util

import redis.clients.jedis.{Jedis, JedisPool, JedisPoolConfig}

object MyRedisUtils {

  var jedisPool : JedisPool = null

  def getJedisClient : Jedis = {
    if(jedisPool == null ){
      var host : String = PropertiesUtils("redis.host")
      var port : String = PropertiesUtils("redis.port")
      val jedisPoolConfig = new JedisPoolConfig()
      jedisPoolConfig.setMaxTotal(100) //最大连接数
      jedisPoolConfig.setMaxIdle(20) //最大空闲
      jedisPoolConfig.setMinIdle(20) //最小空闲
      jedisPoolConfig.setBlockWhenExhausted(true) //忙碌时是否等待
      jedisPoolConfig.setMaxWaitMillis(5000) //忙碌时等待时长 毫秒
      jedisPoolConfig.setTestOnBorrow(true) //每次获得连接的进行测试

      jedisPool =  new JedisPool(jedisPoolConfig,host,port.toInt)
    }
```

```
    jedisPool.getResource
  }

}
```

3）添加偏移量工具类

```
object OffsetManagerUtil {

    /**
      * 从 Redis 中读取偏移量
      *   Redis   格 式 ：  type=>Hash     [key=>offset:topic:groupId
field=>partitionId value=>偏移量值] expire 不需要指定
      *
      * @param topicName 主题名称
      * @param groupId   消费者组
      * @return 当前消费者组中，消费的主题对应的分区的偏移量信息
      *         KafkaUtils.createDirectStream 在读取数据的时候封装了
Map[TopicPartition,Long]
      */
    def    getOffset(topicName:    String,    groupId:    String):
Map[TopicPartition, Long] = {
      //获取 Redis 客户端
      val jedis: Jedis = RedisUtil.getJedisClient
      //拼接 Reids 中存储偏移量的 key
      val offsetKey: String = "offset:" + topicName + ":" + groupId
      //根据 key 从 Reids 中获取数据
      val     offsetMap:     java.util.Map[String,     String]     =
jedis.hgetAll(offsetKey)
      //关闭客户端
      jedis.close()
      //将 Java 的 Map 转换为 Scala 的 Map，方便后续操作
      import scala.collection.JavaConverters._
      val     kafkaOffsetMap:     Map[TopicPartition,     Long]     =
offsetMap.asScala.map {
        case (partitionId, offset) => {
          println("读取分区偏移量：" + partitionId + ":" + offset)
          //将 Redis 中保存的分区对应的偏移量进行封装
          (new     TopicPartition(topicName,     partitionId.toInt),
offset.toLong)
        }
      }.toMap
      kafkaOffsetMap
    }

    /**
      * 向 Redis 中保存偏移量
      *   Reids   格 式 ：  type=>Hash     [key=>offset:topic:groupId
field=>partitionId value=>偏移量值] expire 不需要指定
      *
      * @param topicName    主题名
      * @param groupId      消费者组
      * @param offsetRanges 当前消费者组中，消费的主题对应的分区的偏移量起
始和结束信息
```

```
    */
   def saveOffset(topicName: String, groupId: String, offsetRanges:
Array[OffsetRange]): Unit = {

    //定义 Java 的 map 集合，用于向 Reids 中保存数据
    val offsetMap: java.util.HashMap[String, String] = new
java.util.HashMap[String, String]()
    //对封装的偏移量数组 offsetRanges 进行遍历
    for (offset <- offsetRanges) {
      //获取分区
      val partition: Int = offset.partition
      //获取结束点
      val untilOffset: Long = offset.untilOffset
      //封装到 Map 集合中
      offsetMap.put(partition.toString, untilOffset.toString)
      //打印测试
      println("保存分区:" + partition + ":" + offset.fromOffset +
"--->" + offset.untilOffset)
    }

    //拼接 Reids 中存储偏移量的 key
    val offsetKey: String = "offset:" + topicName + ":" + groupId

    //如果需要保存的偏移量不为空 执行保存操作
    if (offsetMap != null && offsetMap.size() > 0) {
      //获取 Redis 客户端
      val jedis: Jedis = RedisUtil.getJedisClient

      //保存到 Redis 中
      jedis.hmset(offsetKey, offsetMap)
      //关闭客户端
      jedis.close()
    }
  }
}
```

4）修补主程序的代码

```
package com.atguigu.gmall.realtime.app

import com.alibaba.fastjson.serializer.SerializeConfig
import com.alibaba.fastjson.{JSON, JSONArray, JSONObject}
import com.atguigu.gmall.realtime.bean.{PageActionLog,
PageDisplayLog, PageLog, StartLog}
import com.atguigu.gmall.realtime.util.{MyKafkaUtils,
MyOffsetUtils}
import org.apache.kafka.clients.consumer.ConsumerRecord
import org.apache.kafka.common.TopicPartition
import org.apache.spark.SparkConf
import org.apache.spark.rdd.RDD
import org.apache.spark.streaming.dstream.{DStream, InputDStream}
import org.apache.spark.streaming.kafka010.{HasOffsetRanges,
OffsetRange}
import org.apache.spark.streaming.{Seconds, StreamingContext}
```

```
/**
  * 消费分流
  * 1. 接收 Kafka 数据流
  *
  * 2. 转换数据结构:
  *      通用的数据结构: Map 或者 JsonObject
  *      专用的数据结构: bean
  *
  * 3. 分流 : 将数据拆分到不同的主题中
  *      启动主题: DWD_START_LOG
  *      页面访问主题: DWD_PAGE_LOG
  *      页面动作主题:DWD_PAGE_ACTION
  *      页面曝光主题:DWD_PAGE_DISPLAY
  *      错误主题:DWD_ERROR_INFO
  */
object BaseLogApp {
  def main(args: Array[String]): Unit = {
    //创建配置对象
    val sparkConf: SparkConf = new
SparkConf().setAppName("base_log_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkConf,Seconds(5))

    //原始主题
    val ods_base_topic : String = "ODS_BASE_LOG"
    //启动主题
    val dwd_start_log : String = "DWD_START_LOG"
    //页面访问主题
    val dwd_page_log : String = "DWD_PAGE_LOG"
    //页面动作主题
    val dwd_page_action : String = "DWD_PAGE_ACTION"
    //页面曝光主题
    val dwd_page_display : String  = "DWD_PAGE_DISPLAY"
    //错误主题
    val dwd_error_info : String  ="DWD_ERROR_INFO"

    //消费组
    val group_id : String = "ods_base_log_group"


    //补充:
    // 从 redis 中读取偏移量
    val offsets: Map[TopicPartition, Long] =
MyOffsetUtils.getOffset(ods_base_topic,group_id)

    // 判断是否能读取到
    var kafkaDStream : DStream[ConsumerRecord[String, String]] =
null
    if(offsets != null && offsets.nonEmpty){
      //redis 中有记录 offset
      //1. 接收 Kafka 数据流
      kafkaDStream =
```

```
MyKafkaUtils.getKafkaDStream(ods_base_topic,ssc,offsets,group_id)
    }else{
      //redis 中没有记录 offset
      //1. 接收 Kafka 数据流
      kafkaDStream =
        MyKafkaUtils.getKafkaDStream(ods_base_topic,ssc,group_id)
    }


    //在数据转换前，提取本次流中 offset 的结束点，
    var offsetRanges: Array[OffsetRange] = null  // driver
    kafkaDStream =  kafkaDStream.transform(  // 每批次执行一次
      rdd => {
        println(rdd.getClass.getName)
        offsetRanges                                                    =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )

    //2. 转换数据结构
    val jsonDStream: DStream[JSONObject] = kafkaDStream.map(
      record => {

        val value: String = record.value()
        println(value)
        val jsonObject: JSONObject = JSON.parseObject(value)

        jsonObject
      }
    )

    //3.切分数据分流
    jsonDStream.foreachRDD(
      rdd => {
        rdd.foreach(
          jsonObj => {
            //TODO 错误日志
            //分流错误日志 判断是否是错误日志，如果是错误日志，直接发送
            val errorObj: JSONObject = jsonObj.getJSONObject("err")
            if(errorObj !=null){
              MyKafkaUtils.send(dwd_error_info,jsonObj.toJSONString)
            }else{
              //提取公共信息
              val          commonObj:          JSONObject          =
jsonObj.getJSONObject("common")
              val mid: String = commonObj.getString("mid")
              val uid: String = commonObj.getString("uid")
              val ar: String = commonObj.getString("ar")
              val ch: String = commonObj.getString("ch")
              val os: String = commonObj.getString("os")
              val md: String = commonObj.getString("md")
              val vc: String = commonObj.getString("vc")
              val isNew: String = commonObj.getString("is_new")
```

```
            val ts: Long = jsonObj.getLong("ts")

            //分流页面日志
            val pageObj: JSONObject = jsonObj.getJSONObject("page")
            if(pageObj != null ){
              //提取字段
              val pageId: String = pageObj.getString("page_id")
              val pageItem: String = pageObj.getString("item")
              val pageItemType: String =
pageObj.getString("item_type")
              val lastPageId: String =
pageObj.getString("last_page_id")
              val duringTime: Long = pageObj.getLong("during_time")

              //封装 bean
              val pageLog =
                PageLog(mid, uid, ar, ch, isNew, md, os, vc, pageId,
lastPageId, pageItem, pageItemType, duringTime, ts)
              //发送 kafka

MyKafkaUtils.send(dwd_page_log,JSON.toJSONString(pageLog,new
SerializeConfig(true)))

              //分流动作日志
              val actionArrayObj: JSONArray =
jsonObj.getJSONArray("actions")
              if(actionArrayObj != null && actionArrayObj.size() >
0 ){
                for(i <- 0 until actionArrayObj.size() ){
                  val actionObj: JSONObject =
actionArrayObj.getJSONObject(i)
                  val actionId: String =
actionObj.getString("action_id")
                  val actionItem: String =
actionObj.getString("item")
                  val actionItemType: String =
actionObj.getString("item_type")
                  //TODO actionts
                  val actionTs: Long = actionObj.getLong("ts")

                  //封装 Bean
                  val pageActionLog =
                    PageActionLog(mid, uid, ar, ch, isNew, md, os, vc,
pageId, lastPageId, pageItem, pageItemType,
duringTime,actionId,actionItem,actionItemType,actionTs, ts)

                  //发送 Kafka

MyKafkaUtils.send(dwd_page_action,JSON.toJSONString(pageActionLog
,new SerializeConfig(true)))

                }
              }

              //分流曝光日志
```

```
              val displayArrayObj: JSONArray =
jsonObj.getJSONArray("displays")
              if(displayArrayObj != null && displayArrayObj.size() >
0 ){
                for(i <- 0 until displayArrayObj.size()){
                  val displayObj: JSONObject =
displayArrayObj.getJSONObject(i)
                  val displayType: String =
displayObj.getString("display_type")
                  val displayItem: String =
displayObj.getString("item")
                  val displayItemType: String =
displayObj.getString("item_type")
                  val displayOrder: String =
displayObj.getString("order")
                  val displayPosId: String =
displayObj.getString("pos_id")

                  //封装 Bean
                  val displayLog = PageDisplayLog(mid, uid, ar, ch,
isNew, md, os, vc, pageId, lastPageId, pageItem, pageItemType,
duringTime,displayType,displayItem,displayItemType,displayOrder,d
isplayPosId,ts)
                  //发送 Kafka

MyKafkaUtils.send(dwd_page_display,JSON.toJSONString(displayLog,n
ew SerializeConfig(true)))
                }
              }

            }

            //分流启动日志
            val startObj: JSONObject =
jsonObj.getJSONObject("start")
            if(startObj != null ){
              val entry: String = startObj.getString("entry")
              val loadingTimeMs: Long =
startObj.getLong("loading_time_ms")
              val openAdId: String =
startObj.getString("open_ad_id")
              val openAdMs: Long = startObj.getLong("open_ad_ms")
              val openAdSkipMs: Long =
startObj.getLong("open_ad_skip_ms")

              //封装 Bean
              val startLog =
StartLog(mid,uid,ar,ch,isNew,md,os,vc,entry,openAdId,loadingTimeM
s,openAdMs,openAdSkipMs,ts)
              //发送 Kafka

MyKafkaUtils.send(dwd_start_log,JSON.toJSONString(startLog,new
SerializeConfig(true)))
            }
```

```
            }
            // foreach 里边  executor 中执行，一条数据执行一次
          }

        )
        //补充：
        //foreachRDD 里边  driver 中执行，一个批次执行一次
        //提交偏移量

MyOffsetUtils.saveOffset(ods_base_topic,group_id,offsetRanges)
      }
    )

    // foreahRDD 外面 driver 中执行，一次启动执行一次

    ssc.start()
    ssc.awaitTermination()
  }
}
```

2.6.7 幂等性操作

目前处理完的数据写到了 kafka,如果程序出现宕机重试，kafka 是没有办法通过唯一性标识实现幂等性识别，但是也没有关系，因为 kafka 中的数据只是用于中间存储,并不会进行统计，所以只要保证不丢失即可，重复数据的幂等性处理可以交给下游处理，只要保证最终统计结果是不会有重复即可。

2.7 优化 - kafka 消息发送问题

2.7.1 缓冲区问题

Kafka 消息的发送分为同步发送和异步发送。 Kafka 默认使用异步发送的方式。Kafka 的生产者将消息进行发送时，会先将消息发送到缓冲区中，待缓冲区写满或者到达指定的时间，才会真正的将缓冲区的数据写到 Broker。

假设消息发送到缓冲区中还未写到 Broker，我们认为数据已经成功写给了 Kafka，接下来会手动的提交 offset, 如果 offset 提交成功，但此刻 Kafka 集群突然出现故障。 缓冲区的数据会丢失，最终导致的问题就是数据没有成功写到 Kafka ，而 offset 已经提交，此部分的数据就会被漏掉。

2.7.2 问题解决 – 策略一

将消息的发送修改为同步发送，保证每条数据都能发送到 Broker。 但带来的问题就是消息是一条一条写给 Broker,会牺牲性能，一般不推荐。

2.7.3 问题解决 – 策略二

1）策略：在手动提交 offset 之前，强制将缓冲区的数据 flush 到 broker

Kafka 的生产者对象提供了 flush 方法， 可以强制将缓冲区的数据刷到 Broker。

2）修补主程序代码

```
package com.atguigu.gmall.realtime.app

import com.alibaba.fastjson.serializer.SerializeConfig
import com.alibaba.fastjson.{JSON, JSONArray, JSONObject}
import com.atguigu.gmall.realtime.bean.{PageActionLog,
PageDisplayLog, PageLog, StartLog}
import com.atguigu.gmall.realtime.util.{MyKafkaUtils,
MyOffsetUtils}
import org.apache.kafka.clients.consumer.ConsumerRecord
import org.apache.kafka.common.TopicPartition
import org.apache.spark.SparkConf
import org.apache.spark.streaming.dstream.{DStream, InputDStream}
import org.apache.spark.streaming.kafka010.{HasOffsetRanges,
OffsetRange}
import org.apache.spark.streaming.{Seconds, StreamingContext}


/**
  * 消费分流
  * 1. 接收 Kafka 数据流
  *
  * 2. 转换数据结构:
  *      通用的数据结构: Map 或者 JsonObject
  *      专用的数据结构: bean
  *
  * 3. 分流 : 将数据拆分到不同的主题中
  *      启动主题: DWD_START_LOG
  *      页面访问主题: DWD_PAGE_LOG
  *      页面动作主题:DWD_PAGE_ACTION
  *      页面曝光主题:DWD_PAGE_DISPLAY
  *      错误主题:DWD_ERROR_INFO
  */
object BaseLogApp {
  def main(args: Array[String]): Unit = {
    //创建配置对象
    val sparkConf: SparkConf = new
SparkConf().setAppName("base_log_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkConf,Seconds(5))

    //原始主题
    val ods_base_topic : String = "ODS_BASE_LOG"
    //启动主题
    val dwd_start_log : String = "DWD_START_LOG"
    //页面访问主题
    val dwd_page_log : String = "DWD_PAGE_LOG"
```

```
    //页面动作主题
    val dwd_page_action : String = "DWD_PAGE_ACTION"
    //页面曝光主题
    val dwd_page_display : String  = "DWD_PAGE_DISPLAY"
    //错误主题
    val dwd_error_info : String  ="DWD_ERROR_INFO"

    //消费者组
    val group_id : String = "ods_base_log_group"

    //补充:
    // 从 redis 中读取便宜量
    val       offsets:       Map[TopicPartition,       Long]       =
MyOffsetUtils.getOffset(ods_base_topic,group_id)

    // 判断是否能读取到
    var kafkaDStream : DStream[ConsumerRecord[String, String]]  =
null
    if(offsets != null && offsets.nonEmpty){
      //redis 中有记录 offset
      //1. 接收 Kafka 数据流
      kafkaDStream =

MyKafkaUtils.getKafkaDStream(ods_base_topic,ssc,offsets,group_id)
    }else{
      //redis 中没有记录 offset
      //1. 接收 Kafka 数据流
      kafkaDStream =
        MyKafkaUtils.getKafkaDStream(ods_base_topic,ssc,group_id)
    }


    //在数据转换前, 提取本次流中 offset 的结束点,
    var offsetRanges: Array[OffsetRange] = null  // driver
    kafkaDStream =  kafkaDStream.transform(  // 每批次执行一次
      rdd => {
        println(rdd.getClass.getName)
        offsetRanges                                                  =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )

    //2. 转换数据结构
    val jsonDStream: DStream[JSONObject] = kafkaDStream.map(
      record => {
        val value: String = record.value()
        val jsonObject: JSONObject = JSON.parseObject(value)
        jsonObject
      }
    )

    //3.切分数据分流
    jsonDStream.foreachRDD(
```

```
      rdd => {
        rdd.foreachPartition(
          iter => {
            for (jsonObj <- iter) {
              //TODO 错误日志
              //分流错误日志 判断是否是错误日志，如果是错误日志，直接发送
              val errorObj: JSONObject = jsonObj.getJSONObject("err")
              if(errorObj !=null){

MyKafkaUtils.send(dwd_error_info,jsonObj.toJSONString)
              }else{
                //提取公共信息
                val          commonObj:          JSONObject          =
jsonObj.getJSONObject("common")
                val mid: String = commonObj.getString("mid")
                val uid: String = commonObj.getString("uid")
                val ar: String = commonObj.getString("ar")
                val ch: String = commonObj.getString("ch")
                val os: String = commonObj.getString("os")
                val md: String = commonObj.getString("md")
                val vc: String = commonObj.getString("vc")
                val isNew: String = commonObj.getString("is_new")
                val ts: Long = commonObj.getLong("ts")

                //分流页面日志
                val          pageObj:          JSONObject          =
jsonObj.getJSONObject("page")
                if(pageObj != null ){
                  //提取字段
                  val pageId: String = pageObj.getString("page_id")
                  val pageItem: String = pageObj.getString("item")
                  val          pageItemType:          String          =
pageObj.getString("item_type")
                  val          lastPageId:          String          =
pageObj.getString("last_page_id")
                  val duringTime: Long = pageObj.getLong("during_time")

                  //封装 bean
                  val pageLog =
                    PageLog(mid, uid, ar, ch, isNew, md, os, vc, pageId,
lastPageId, pageItem, pageItemType, duringTime, ts)
                  //发送 kafka

MyKafkaUtils.send(dwd_page_log,JSON.toJSONString(pageLog,new
SerializeConfig(true)))

                  //分流动作日志
                  val        actionArrayObj:        JSONArray        =
jsonObj.getJSONArray("actions")
                  if(actionArrayObj != null && actionArrayObj.size() >
0 ){
                    for(i <- 0 until actionArrayObj.size() ){
                      val        actionObj:        JSONObject        =
actionArrayObj.getJSONObject(i)
                      val          actionId:          String          =
```

```
actionObj.getString("action_id")
                    val         actionItem:         String         =
actionObj.getString("item")
                    val        actionItemType:        String        =
actionObj.getString("item_type")
                    //TODO actionts
                    val actionTs: Long = actionObj.getLong("ts")

                    //封装 Bean
                    val pageActionLog =
                      PageActionLog(mid, uid, ar, ch, isNew, md, os,
vc,      pageId,      lastPageId,      pageItem,      pageItemType,
duringTime,actionId,actionItem,actionItemType,actionTs, ts)

                    //发送 Kafka

MyKafkaUtils.send(dwd_page_action,JSON.toJSONString(pageActionLog
,new SerializeConfig(true)))

                  }
                }

                //分流曝光日志
                val        displayArrayObj:        JSONArray        =
jsonObj.getJSONArray("displays")
                if(displayArrayObj != null && displayArrayObj.size() >
0 ){
                  for(i <- 0 until displayArrayObj.size()){
                    val        displayObj:        JSONObject        =
displayArrayObj.getJSONObject(i)
                    val         displayType:         String         =
displayObj.getString("display_type")
                    val         displayItem:         String         =
displayObj.getString("item")
                    val        displayItemType:        String        =
displayObj.getString("item_type")
                    val         displayOrder:         String         =
displayObj.getString("order")
                    val         displayPosId:         String         =
displayObj.getString("pos_id")

                    //封装 Bean
                    val displayLog = PageDisplayLog(mid, uid, ar, ch,
isNew, md, os, vc, pageId, lastPageId, pageItem, pageItemType,
duringTime,displayType,displayItem,displayItemType,displayOrder,d
isplayPosId,ts)
                    //发送 Kafka

MyKafkaUtils.send(dwd_page_display,JSON.toJSONString(displayLog,n
ew SerializeConfig(true)))
                  }
                }

              }
```

```
              //分流启动日志
              val          startObj:          JSONObject          =
jsonObj.getJSONObject("start")
              if(startObj != null ){
                val entry: String = startObj.getString("entry")
                val          loadingTimeMs:          Long          =
startObj.getLong("loading_time_ms")
                val           openAdId:           String           =
startObj.getString("open_ad_id")
                val openAdMs: Long = startObj.getLong("open_ad_ms")
                val          openAdSkipMs:          Long          =
startObj.getLong("open_ad_skip_ms")

                //封装 Bean
                val                    startLog                    =
StartLog(mid,uid,ar,ch,isNew,md,os,vc,entry,openAdId,loadingTimeM
s,openAdMs,openAdSkipMs,ts)
                //发送 Kafka

MyKafkaUtils.send(dwd_start_log,JSON.toJSONString(startLog,new
SerializeConfig(true)))
              }

            }
          }

          // 一个批次一个分区提交一次
          MyKafkaUtils.flush()
        }
      )
        //foreachRDD 里边  driver 中执行，一个批次执行一次
        //提交偏移量

MyOffsetUtils.saveOffset(ods_base_topic,group_id,offsetRanges)
    }
  )
  //foreachRDD 外面  driver 中执行，启动应用程序执行一次.
  ssc.start()
  ssc.awaitTermination()
 }
}
```

第 3 章 业务数据采集和分流

3.1 整体架构

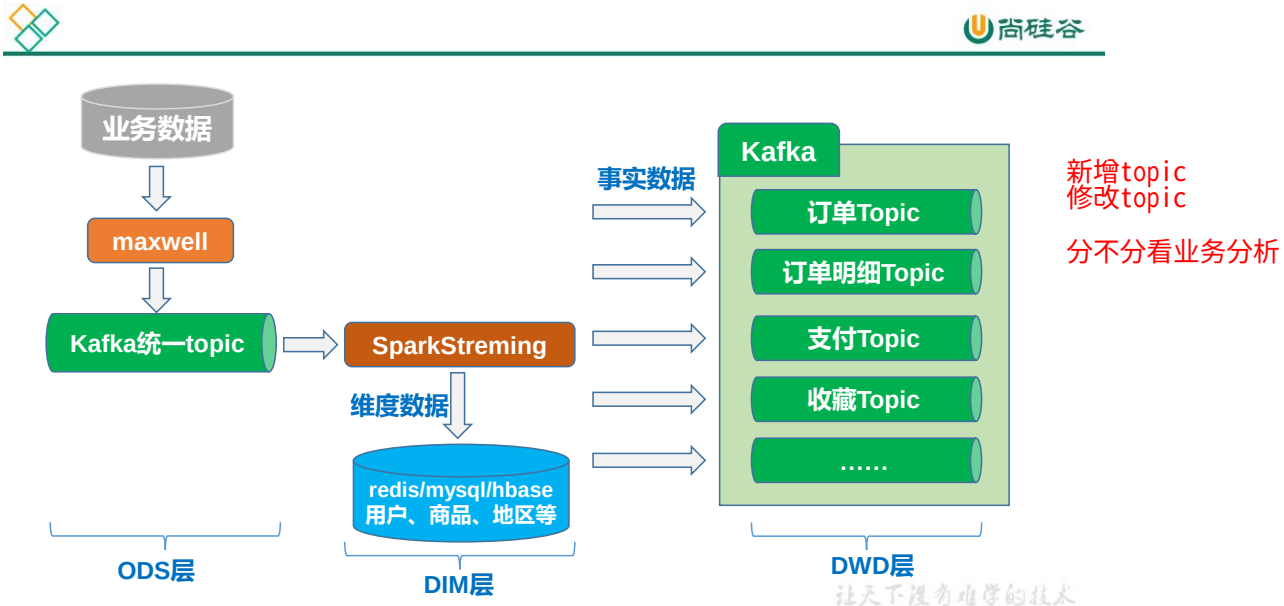

业务数据库的采集主要是基于对数据库的变化的实时监控。目前市面上的开源产品主要是 Canal 和 Maxwell。要利用这些工具实时采集数据到 kafka，以备后续处理。

Maxwell 采集的日志数据，默认是放在一个统一的 kafka 的 Topic 中，为了后续方便处理要进行以表为单位拆分到不同 kafka 的 Topic 中。

针对维度数据，要单独保存。通常考虑用 redis、hbase、mysql、kudu 等通过唯一键查询性能较快的数据库中。

3.2 Maxwell 简介

3.2.1 什么是 Maxwell

Maxwell 是由美国 Zendesk 公司开源，用 Java 编写的 MySQL 变更数据抓取软件。它会实时监控 Mysql 数据库的数据变更操作（包括 insert、update、delete），并将变更数据以 JSON 格式发送给 Kafka、Kinesi 等流数据处理平台。

官网地址：http://maxwells-daemon.io/

3.2.2 MySQL 主从复制

1）主从复制的应用场景如下

（1）做数据库的热备：主数据库服务器故障后，可切换到从数据库继续工作。

（2）分离：主数据库只负责业务数据的写入操作，而多个从数据库只负责业务数据的查询工作，在读多写少场景下，可以提高数据库工作效率

2）MySQL 主从复制工作原理

（1）Master 主库将数据变更记录，写到二进制日志(binary log)中

（2）Slave 从库向 mysql master 发送 dump 协议，将 master 主库的 binary log events 拷贝到它的中继日志(relay log)

（3）Slave 从库读取并回放中继日志中的事件，将改变的数据同步到自己的数据库。

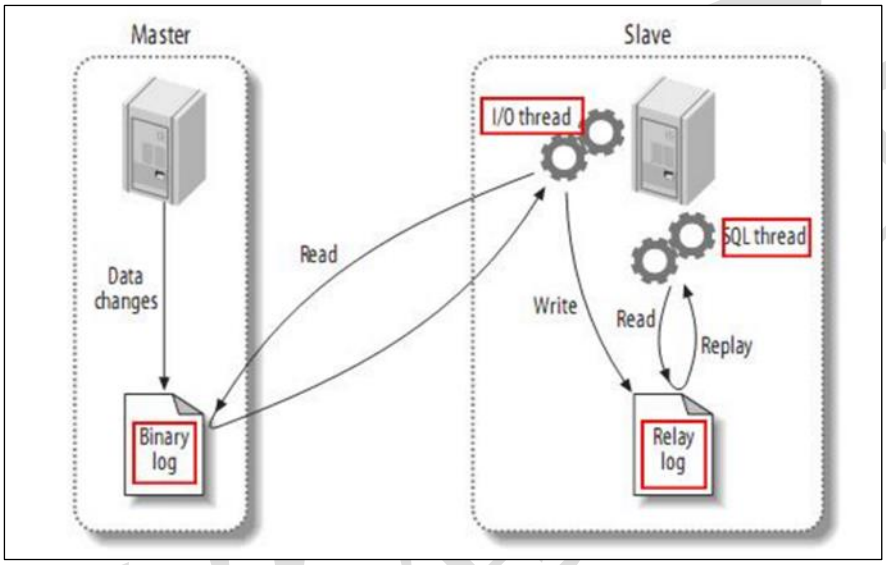

3）binlog

（1）什么是 binlog

MySQL 的二进制日志可以说 MySQL 最重要的日志了，它记录了所有的 DDL 和 DML(除了数据查询语句)语句，以事件形式记录，还包含语句所执行的消耗的时间，MySQL 的二进制日志是事务安全型的。

一般来说开启二进制日志大概会有 1%的性能损耗。

二进制日志包括两类文件：二进制日志索引文件（文件名后缀为.index）用于记录所有的二进制文件，二进制日志文件（文件名后缀为.00000*）记录数据库所有的 DDL 和 DML(除了数据查询语句)语句事件。

（2）binlog 的分类设置

mysql binlog 的格式有三种，分别是 STATEMENT,MIXED,ROW。

```
binlog_format= statement|mixed|row
```

- statement

语句级，binlog 会记录每次一执行写操作的语句。相对 row 模式节省空间，但是可能产生不一致性，比如 update tt set create_date=now() 如果用 binlog 日志进行恢复，由于执行时间不同可能产生的数据就不同。

优点： 节省空间

缺点： 有可能造成数据不一致。

- row

行级， binlog 会记录每次操作后每行记录的变化。

优点：保持数据的绝对一致性。因为不管 sql 是什么，引用了什么函数，他只记录执行后的效果。

缺点：占用较大空间。

- mixed

statement 的升级版，一定程度上解决了因为一些情况而造成的 statement 模式不一致问题 。默认还是 statement，在某些情况下譬如：当函数中包含 UUID() 时；包含 AUTO_INCREMENT 字段的表被更新时；执行 INSERT DELAYED 语句时；用 UDF 时；会按照 ROW 的方式进行处理

优点：节省空间，同时兼顾了一定的一致性。

缺点：还有些极个别情况依旧会造成不一致，另外 statement 和 mixed 对于需要对 binlog 的监控的情况都不方便。

综合上面对比，Maxwell 想做监控分析，选择 row 格式比较合适。

3.2.3 Maxwell 工作原理

很简单，就是将自己伪装成 slave，并遵循 MySQL 主从复制的协议，从 master 同步数据。

Maxwell工作原理

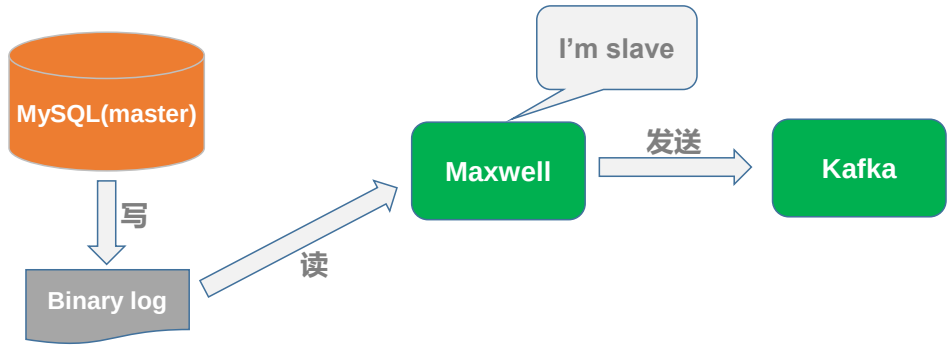

3.2.4 Maxwell 安装

1）将安装包上传到 hadoop102 节点的/opt/software 目录

2）解压到/opt/module/目录下

```
[atguigu@hadoop102 software]$ tar -zxvf maxwell-1.29.2.tar.gz -C /opt/module/
```

3）修改名称

```
[atguigu@hadoop102 module]$ mv maxwell-1.29.2/ maxwell
```

3.3 采集业务数据

3.3.1 MySQL 部分

1）安装 MySQL（略）

2）创建业务数据库（直接使用离线数仓的即可）

3）导入数据表（直接使用离线数仓的即可）

4）修改/etc/my.cnf 文件，开启 binlog

```
[atguigu@hadoop102 module]$ sudo vim /etc/my.cnf

server-id=1
log-bin=mysql-bin
binlog_format=row
binlog-do-db=gmall
```

注意：binlog-do-db 根据自己的情况进行修改，指定具体要同步的数据库。

5）重启 MySQL 使配置生效 service mysql start

```
[atguigu@hadoop102 ~]$ sudo systemctl restart mysqld
```

到/var/lib/mysql 目录下查看是否生成 binlog 文件

```
-rw-r-----. 1 mysql mysql     154 12 月 28 17:40 mysql-bin.000001
-rw-r-----. 1 mysql mysql      19 12 月 28 17:40 mysql-bin.index
```

3.3.2 模拟数据

1）上传 jar 和 properties 文件上传到/opt/module/db_log 目录下

```
[atguigu@hadoop102 db_log]$
[atguigu@hadoop102 db_log]$ ll
总用量 14780
-rw-r--r--. 1 atguigu atguigu        1601 9 月  25 16:24
application.properties
-rw-r--r--. 1 atguigu atguigu 15127607 2 月   1 2021
gmall2020-mock-db-2021-01-22.jar
```

2）修改 application.properties 中数据库连接信息

```
spring.datasource.driver-class-name=com.mysql.jdbc.Driver
spring.datasource.url=jdbc:mysql://hadoop102:3306/gmall?character
Encoding=utf-8&useSSL=false&serverTimezone=GMT%2B8
spring.datasource.username=root
spring.datasource.password=123456
```

3）模拟生成数据

```
[atguigu@hadoop102 db_log]$ java -jar
gmall2020-mock-db-2021-01-22.jar
```

4）再次到/var/lib/mysql 目录下，查看 binlog 的改动

```
-rw-r-----. 1 mysql mysql  345632 12 月 28 17:53 mysql-bin.000001
-rw-r-----. 1 mysql mysql      19 12 月 28 17:40 mysql-bin.index
```

3.3.3 赋权限

1）给 maxwell 创建用户并赋权限

```
mysql> CREATE USER 'maxwell'@'%' IDENTIFIED BY 'maxwell';
mysql> GRANT SELECT, REPLICATION CLIENT, REPLICATION SLAVE ON *.* TO
'maxwell'@'%';
```

3.3.4 Maxwell 部分

1）创建数据库，用于存储 Maxwell 运行过程中的一些数据,包括 binlog 同步的断点位置等

```
mysql> create database maxwell;
mysql> GRANT ALL ON maxwell.* TO 'maxwell'@'%';
```

2）修改 Maxwell 配置文件名字

```
[atguigu@hadoop102 maxwell]$ mv config.properties.example
config.properties
```

3）修改 Maxwell 配置文件内容

```
[atguigu@hadoop102 maxwell]$ vim config.properties

#Maxwell 数据发送目的地，可选配置有
stdout|file|kafka|kinesis|pubsub|sqs|rabbitmq|redis
```

```
producer=kafka
#目标 Kafka 集群地址
kafka.bootstrap.servers=hadoop102:9092,hadoop103:9092
#目标 Kafka topic，可静态配置，例如:maxwell，也可动态配置，例如: %{database}_%{table}
kafka_topic=ODS_BASE_DB_M

#MySQL 相关配置
host=hadoop102
user=maxwell
password=maxwell
jdbc_options=useSSL=false&serverTimezone=Asia/Shanghai
```

4）启动 Maxwell

```
[atguigu@hadoop102 maxwell]$ bin/maxwell --config config.properties --daemon
```

5）查看进程

```
[atguigu@hadoop102 bin]$ jps
2428 Maxwell
```

6）启动 Kafka 消费客户端测试，查看消费情况

```
[atguigu@hadoop102 kafka]$ bin/kafka-console-consumer.sh --bootstrap-server hadoop102:9092 --topic ODS_BASE_DB_M
```

7）模拟生成数据，查看是否能消费到数据

```
[atguigu@hadoop102 db_log]$ java -jar gmall2020-mock-db-2021-01-22.jar
```

3.4 业务数据消费分流

3.4.1 Maxwell 数据格式

```
{"database":"gmall","table":"order_info","type":"update","ts":1640862565,"xid":3159,"commit":true,"data":{"id":5319,"consignee":"王洁
1111","consignee_tel":"13559267642","total_amount":10130.00,"order_status":"1004","user_id":12,"payment_way":null,"delivery_address":"第 3 大街第 29 号楼 8 单元 674 门","order_comment":"描述314649","out_trade_no":"481626686333178","trade_body":"Redmi 10X 4G Helio G85 游戏芯 4800 万超清四摄 5020mAh 大电量 小孔全面屏 128GB 大存储 8GB+128GB 明月灰 游戏智能手机 小米 红米等 4 件商品","create_time":"2021-09-24 19:05:45","operate_time":"2021-09-24 19:05:45","expire_time":"2021-09-24
19:20:45","process_status":null,"tracking_no":null,"parent_order_id":null,"img_url":"http://img.gmall.com/844142.jpg","province_id":13,"activity_reduce_amount":0.00,"coupon_reduce_amount":0.00,"original_total_amount":10120.00,"feight_fee":10.00,"feight_fee_reduce":null,"refundable_time":null},"old":{"consignee":"王洁"}}
```

3.4.2 消费分流

Maxwell 会追踪整个数据库的变更，把所有的数据变化都发到一个 topic 中了，但是为

了后续处理方便，应该将事实表的数据分流到不同的 topic 中，将维度表的数据写入到 redis 中。

1）分流业务代码

```
package com.atguigu.gmall.realtime.app

import java.util

import com.alibaba.fastjson.{JSON, JSONArray, JSONObject}
import com.atguigu.gmall.realtime.util.{MyKafkaUtils, MyOffsetUtils, MyRedisUtils}
import org.apache.kafka.clients.consumer.ConsumerRecord
import org.apache.kafka.common.TopicPartition
import org.apache.spark.SparkConf
import org.apache.spark.broadcast.Broadcast
import org.apache.spark.streaming.dstream.DStream
import org.apache.spark.streaming.kafka010.{HasOffsetRanges, OffsetRange}
import org.apache.spark.streaming.{Seconds, StreamingContext}
import redis.clients.jedis.Jedis

/**
  * 业务数据分流
  * 1. 读取偏移量
  * 2. 接收 kakfa 数据
  * 3. 提取偏移量结束点
  * 4. 转换结构
  * 5. 分流处理
  *    5.1 事实数据分流-> kafka
  *    5.2 维度数据分流-> redis
  * 6. 提交偏移量
  */
object BaseDBApp_maxwell {
  def main(args: Array[String]): Unit = {

    val sparkConf: SparkConf = new SparkConf().setAppName("base_db_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkConf,Seconds(5))

    val topic = "ODS_BASE_DB_M"
    val groupId = "base_db_group"


    //1.读取偏移量
    val offsets: Map[TopicPartition, Long] = MyOffsetUtils.getOffset(topic,groupId)

    //2. 接收 kafka 数据
    var kafkaDStream : DStream[ConsumerRecord[String,String ]] = null
    if(offsets != null && offsets.nonEmpty){
      kafkaDStream =
```

```
MyKafkaUtils.getKafkaDStream(topic,ssc,offsets,groupId)
    }else{
      kafkaDStream = MyKafkaUtils.getKafkaDStream(topic,ssc,groupId)
    }


    //3. 提取偏移量结束点
    var  offsetRanges: Array[OffsetRange] = null
    kafkaDStream  = kafkaDStream.transform(
      rdd => {
        offsetRanges                                                    =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )

    //4. 转换结构
    val jsonObjDstream: DStream[JSONObject] = kafkaDStream.map(
      record => {
        val jsonString: String = record.value()
        val jSONObject: JSONObject = JSON.parseObject(jsonString)
        jSONObject
      }
    )

    //5. 分流

    // 5.1 事实数据
    // 5.2 维度数据

    jsonObjDstream.foreachRDD(
      rdd => {
        val jedis: Jedis = MyRedisUtils.getJedisClient
        val dimTableKey : String = "DIM:TABLES"
        val factTableKey : String = "FACT:TABLES"
        //从 redis 中读取表清单
        val dimTables: util.Set[String] = jedis.smembers(dimTableKey)
        val          factTables:          util.Set[String]          =
jedis.smembers(factTableKey)
        println("检查维度表: " + dimTables)
        println("检查事实表: " + factTables)
        //做成广播变量
        val      dimTablesBC:      Broadcast[util.Set[String]]      =
ssc.sparkContext.broadcast(dimTables)
        val      factTablesBC:      Broadcast[util.Set[String]]      =
ssc.sparkContext.broadcast(factTables)

        jedis.close()


        //只要有一个批次执行一次，且在 executor 中执行的代码， 就需要用
foreachPartittion
        rdd.foreachPartition(
          jsonObjIter => {
```

```
          //获取 redis 连接
          val jedis: Jedis = MyRedisUtils.getJedisClient
          for (jsonObj <- jsonObjIter) {
            //提取表名
            val tableName: String = jsonObj.getString("table")
            //提取操作类型
            val optType: String = jsonObj.getString("type")
            val opt: String = optType match {
              case "insert" => "I"
              case "update" => "U"
              case "delete" => "D"
              case _ => null // DDL 操作，例如：CREATE ALTER
TRUNCATE ....
            }
            if(opt != null ){

            //提取修改后的数据
            val dataJsonArray: JSONObject =
jsonObj.getJSONObject("data")
            //事实表数据
            if(factTablesBC.value.contains(tableName)){
              // 拆分到指定的主题
              // topic => DWD_[TABLE_NAME]_[I/U/D]
                val topicName =
s"DWD_${tableName.toUpperCase()}_$opt"

                  val key: String = dataJsonArray.getString("id")
                  //发送 kafka
                  MyKafkaUtils.send(topicName,key,
dataJsonArray.toJSONString)

              }

              //维度表处理
              if(dimTablesBC.value.contains(tableName)){
                //val jedis: Jedis = MyRedisUtils.getJedisClient
                // 存储类型的选择： String 、 set 、 hash ？
                // key : DIM:[table_name]:[主键]
                // value : 整条数据的 json 串
                  val id: String = dataJsonArray.getString("id")
                  val redisKey : String =
s"DIM:${tableName.toUpperCase()}:$id"
                  val redisValue : String = dataJsonArray.toJSONString
                  jedis.set(redisKey,redisValue)

                //jedis.close()
              }
            }
          }
          jedis.close()
          MyKafkaUtils.flush()
        }
      )
      //6.提交偏移量
```

```
        MyOffsetUtils.saveOffset(topic,groupId,offsetRanges)
      }
    )
    ssc.start()
    ssc.awaitTermination()
  }
}
```

3.4.3 历史维度数据初始引导

1）Maxwell 提供了 bootstrap 功能来进行历史数据的全量同步，命令如下：

```
[atguigu@hadoop102 maxwell]$ bin/maxwell-bootstrap --config config.properties --database gmall --table user_info
```

2）Bootstrap 数据格式

```
{
    "database": "fooDB",
    "table": "barTable",
    "type": "bootstrap-start",
    "ts": 1450557744,
    "data": {}
}
{
    "database": "fooDB",
    "table": "barTable",
    "type": "bootstrap-insert",
    "ts": 1450557744,
    "data": {
        "txt": "hello"
    }
}
{
    "database": "fooDB",
    "table": "barTable",
    "type": "bootstrap-insert",
    "ts": 1450557744,
    "data": {
        "txt": "bootstrap!"
    }
}
{
    "database": "fooDB",
    "table": "barTable",
    "type": "bootstrap-complete",
    "ts": 1450557744,
    "data": {}
}
```

注意事项：

第一条 type 为 bootstrap-start 和最后一条 type 为 bootstrap-complete 的数据，是 bootstrap 开始和结束的标志，不包含数据，中间的 type 为 bootstrap-insert 的数据才包含数据。

一次 bootstrap 输出的所有记录的 ts 都相同，为 bootstrap 开始的时间。

1）修改分流代码

```
package com.atguigu.gmall.realtime.app

import java.util

import com.alibaba.fastjson.{JSON, JSONArray, JSONObject}
import com.atguigu.gmall.realtime.util.{MyKafkaUtils, MyOffsetUtils,
MyRedisUtils}
import org.apache.kafka.clients.consumer.ConsumerRecord
import org.apache.kafka.common.TopicPartition
import org.apache.spark.SparkConf
import org.apache.spark.broadcast.Broadcast
import org.apache.spark.streaming.dstream.DStream
import       org.apache.spark.streaming.kafka010.{HasOffsetRanges,
OffsetRange}
import org.apache.spark.streaming.{Seconds, StreamingContext}
import redis.clients.jedis.Jedis

/**
  * 业务数据分流
  * 1. 读取偏移量
  * 2. 接收 kakfa 数据
  * 3. 提取偏移量结束点
  * 4. 转换结构
  * 5. 分流处理
  *    5.1 事实数据分流-> kafka
  *    5.2 维度数据分流-> redis
  * 6. 提交偏移量
  */
object BaseDBApp_maxwell {
  def main(args: Array[String]): Unit = {

    val          sparkConf:          SparkConf          =          new
SparkConf().setAppName("base_db_app").setMaster("local[4]")
    val ssc = new StreamingContext(sparkConf,Seconds(5))

    val topic = "ODS_BASE_DB_M"
    val groupId = "base_db_group"


    //1.读取偏移量
    val       offsets:       Map[TopicPartition,       Long]       =
MyOffsetUtils.getOffset(topic,groupId)

    //2. 接收 kafka 数据
    var  kafkaDStream  :  DStream[ConsumerRecord[String,String  ]]  =
null
    if(offsets != null && offsets.nonEmpty){
      kafkaDStream                                                  =
MyKafkaUtils.getKafkaDStream(topic,ssc,offsets,groupId)
    }else{
      kafkaDStream = MyKafkaUtils.getKafkaDStream(topic,ssc,groupId)
    }
```

```
    //3. 提取偏移量结束点
    var  offsetRanges: Array[OffsetRange] = null
    kafkaDStream  = kafkaDStream.transform(
      rdd => {
        offsetRanges                                                    =
rdd.asInstanceOf[HasOffsetRanges].offsetRanges
        rdd
      }
    )

    //4. 转换结构
    val jsonObjDstream: DStream[JSONObject] = kafkaDStream.map(
      record => {
        val jsonString: String = record.value()
        val jSONObject: JSONObject = JSON.parseObject(jsonString)
        jSONObject
      }
    )

    //5. 分流
    // 5.1 事实数据
    // 5.2 维度数据

    jsonObjDstream.foreachRDD(
      rdd => {
        val jedis: Jedis = MyRedisUtils.getJedisClient
        val dimTableKey : String = "DIM:TABLES"
        val factTableKey : String = "FACT:TABLES"
        //从 redis 中读取表清单
        val dimTables: util.Set[String] = jedis.smembers(dimTableKey)
        val          factTables:          util.Set[String]          =
jedis.smembers(factTableKey)
        println("检查维度表: " + dimTables)
        println("检查事实表: " + factTables)
        //做成广播变量
        val      dimTablesBC:      Broadcast[util.Set[String]]      =
ssc.sparkContext.broadcast(dimTables)
        val      factTablesBC:      Broadcast[util.Set[String]]      =
ssc.sparkContext.broadcast(factTables)

        jedis.close()


        //只要有一个批次执行一次，且在 executor 中执行的代码， 就需要用
foreachPartittion
        rdd.foreachPartition(
          jsonObjIter => {
            //获取 redis 连接
            val jedis: Jedis = MyRedisUtils.getJedisClient
            for (jsonObj <- jsonObjIter) {
              //提取表名
              val tableName: String = jsonObj.getString("table")
```

```
            //提取操作类型
            val optType: String = jsonObj.getString("type")
            val opt: String = optType match {
              case "bootstrap-insert" => "I"
              case "insert" => "I"
              case "update" => "U"
              case "delete" => "D"
              case _ => null // DDL 操作，例如：CREATE ALTER
TRUNCATE ....
            }
            if(opt != null ){

            //提取修改后的数据
            val dataJsonArray: JSONObject =
jsonObj.getJSONObject("data")
            //事实表数据
            if(factTablesBC.value.contains(tableName)){
              // 拆分到指定的主题
              // topic => DWD_[TABLE_NAME]_[I/U/D]
                val topicName =
s"DWD_${tableName.toUpperCase()}_$opt"

                  val key: String = dataJsonArray.getString("id")
                  //发送 kafka
                  MyKafkaUtils.send(topicName,key,
dataJsonArray.toJSONString)

              }

              //维度表处理
              if(dimTablesBC.value.contains(tableName)){
                //val jedis: Jedis = MyRedisUtils.getJedisClient
                // 存储类型的选择： String 、 set 、 hash ？
                // key : DIM:[table_name]:[主键]
                // valu e : 整条数据的 json 串
                  val id: String = dataJsonArray.getString("id")
                  val redisKey : String =
s"DIM:${tableName.toUpperCase()}:$id"
                  val redisValue : String = dataJsonArray.toJSONString
                  jedis.set(redisKey,redisValue)

                //jedis.close()
              }
            }
          }
          jedis.close()
          MyKafkaUtils.flush()
        }
      )
      //6.提交偏移量
      MyOffsetUtils.saveOffset(topic,groupId,offsetRanges)
    }
  )
  ssc.start()
```

```
    ssc.awaitTermination()
  }
}
```

2）测试引导历史数据

```
[atguigu@hadoop102 maxwell]$ bin/maxwell-bootstrap --config config.properties --database gmall --table user_info
```

3.5 数据处理顺序性

在实时计算中，对业务数据的计算，要考虑到数据处理的顺序， 即能否依照数据改变的顺序进行处理。

假设一个场景，如果将某个用户数据的姓名字段进行多次更改，由原先的 A 改为 B 再改为 C，在数据库层面最终的结果为 C， 但是我们能否保证数据经过实时处理后，在 DIM 层存储的结果也为 C，可不可能存储的结果为 B。

我们依次审视一下，在实时处理的各个环节中，是否能保证数据的顺序？如果不能保证，是在哪个环节出的问题，最终导致存储的结果不正确。

3.5.1 分析

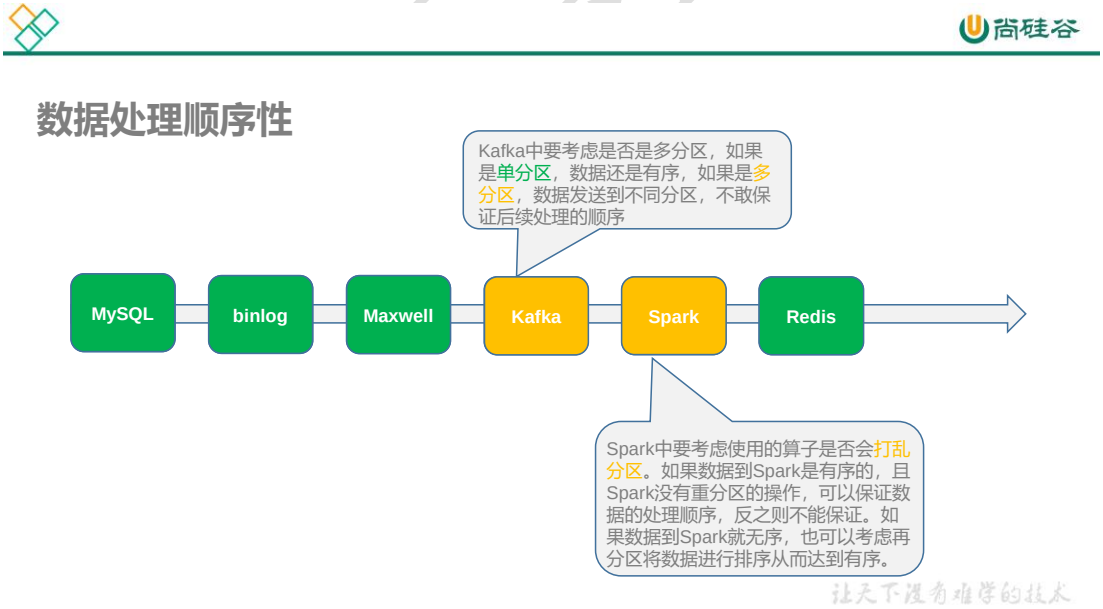

3.5.2 解决

通过分析，目前我们的计算过程中，只有可能在 Kafka 环节出现数据乱序，导致最终存储的结果不正确。如果想要保证数据处理的顺序性，我们可以将同一条数据的修改发往 topic 的同一个分区中。需要修改 maxwell 的配置文件，指定发送数据到 kafka 时要使用分区键。

1）修改 config.properties 文件中的如下配置:

```
producer_partition_by=column
producer_partition_columns=id
producer_partition_by_fallback=table
```

第 4 章 总结